

Reporte de avance — Hackathon 2026

Equipo: Oliv-IA

Integrantes: Laura Rodríguez, Ariadna Vargas, Samuel Montoya

Fecha de la medición: 2 de octubre de 2026, 12:26 (última corrida completa sobre las 50 preguntas de muestra)

1. Puntaje sobre las preguntas de muestra

Resultado de `python scripts/evaluate.py --submission data/processed/bench_generacion/qwen3-8b.jsonl --split sample`.

Componente	Puntos obtenidos	Puntos posibles
Exactitud en cerradas (10/15 = 0,667)	13,33	20
Calidad de citación (índice 0,837; 0 % sin respaldo)	16,73	20
Abstención calibrada (0,837; 36 bien, 7 mal)	8,37	10
Total automático sin RAGAS	38,43	50
Corrección en texto libre: semiabiertas y abiertas (RAGAS 0,457; referencia 0,451)*	13,72	30

* Medido con `--ragas` sobre la corrida anterior de Qwen3-8B (35 ítems juzgados: 30 semiabiertos y 5 abiertos), cuyo total fue 51,23/80. El evaluador da un solo puntaje para ambos formatos.

Observaciones sobre el resultado: Qwen3-8B superó a Llama-3.1-8B (32,68/50) con los mismos pasajes recuperados, por eso lo elegimos como modelo generador. Con el filtro que elimina las citas ausentes de los pasajes, el puntaje fue 37,51. Dos ajustes lo subieron a 38,43: pedir al modelo que nombre la norma por la que pregunta el enunciado y reintentar con penalización de repetición cuando entra en bucle.

2. Estado del corpus

Métrica	Valor
Documentos incorporados	476 (de 499 intentados): 278 leyes, 132 sentencias, 38 decretos, 16 actos legislativos, 7 códigos, la Constitución y la Decisión Andina 486
Fragmentos indexados	60.329
Áreas del banco con cobertura	10 de 10; están 201 de las 225 normas de <code>seed_targets.json</code> , que fundamentan ~96 % de sus ítems
Áreas del banco sin cobertura	Ninguna; las más delgadas son laboral (52 documentos), mercados (54) y civil (54)

Fuentes consultadas: Secretaría General del Senado (339 documentos), Relatoría de la Corte Constitucional (115), Corte Suprema de Justicia (14), Consejo de Estado (4), DIAN (3) y Comunidad Andina (1). Texto extraído sin OCR.

3. Arquitectura actual

Componente	Elección
Encoder	BAAI/bge-m3 (vectores de 1.024 dimensiones), índice FAISS exacto
Decoder	Qwen3-8B cuantizado a 8 bits, temperatura 0, semilla fija y salida forzada al formato JSON del esquema
Estrategia de recuperación	Híbrida: BM25 (léxica) y búsqueda densa aportan 10 candidatos cada una, se fusionan y un <i>reranker</i> (bge-reranker-v2-m3) elige los 10 mejores. Si la pregunta nombra una norma, sus artículos entran directamente; en cerradas se garantiza un pasaje por opción. En las muestras, la norma correcta aparece entre los 10 pasajes en el 89 % de los casos y el artículo exacto en el 71 %
Segmentación del corpus	Un fragmento por artículo (máx. 300 palabras), encabezado con la norma y el artículo de origen; sentencias por secciones; se excluye el texto derogado o declarado inexecutable
Mecanismo de abstención	Verificación posterior a la generación: se elimina toda cita que no figure en los pasajes recuperados, y el sistema se abstiene si no queda ninguna cita respaldada o si la generación falla tras un reintento

4. Riesgos identificados

- Huecos del corpus:** 23 descargas fallaron (p. ej. Ley 153 de 1887, Leyes 50 y 54 de 1990, Decreto 1625 de 2016), laboral es el área más delgada y hay 9.836 fragmentos duplicados. Reintentaremos esas normas desde SUIN-Juriscol y eliminaremos los duplicados, verificando que el puntaje no baje.
- Cerradas y abstención:** 3 cerradas fallan aunque la evidencia correcta está entre los 10 pasajes, y hay 7 respuestas erróneas frente a 0 abstenciones. Ajustaremos las instrucciones para cerradas y fijaremos un umbral de confianza de la recuperación por debajo del cual el sistema se abstenga.
- Tiempo de ejecución:** las 50 muestras tardan 725 s, lo que proyecta ~4,0 h para las 992 (~38 s por pregunta abierta), dentro de las ~6 h disponibles. Guardaremos el avance pregunta por pregunta para reanudar si el proceso se interrumpe.
- Determinismo en la verificación en vivo:** el motor de inferencia en GPU mostró variación entre corridas con la misma entrada. Fijaremos la semilla, probaremos la regeneración de respuestas y congelaremos el índice en la entrega.
- Entregables del sábado:** faltan el contenedor reproducible con comando único, la interfaz conectada al sistema, `CORPUS.md` y la publicación del corpus y del índice.